

Medición de percepciones y preferencias sobre meritocracia en etapa escolar en Chile

Andreas Laffert Tamayo¹, Tomás Urzúa²

¹Instituto de Sociología, Pontificia Universidad Católica de Chile

²Departamento de Sociología, Universidad de Chile

1 Introducción

La creencia de que las desigualdades económicas se justifican por diferencias en elementos meritocráticos—como el esfuerzo individual y el talento (Young, 1958)—ha sido identificada como un mecanismo clave para explicar la persistencia de las desigualdades. Desde sus inicios, las instituciones educativas han sido fundamentales en la promoción de estos valores, debido a su conexión con las promesas de movilidad social y mejores oportunidades de vida (Dubet, 2011). Investigaciones previas muestran que las personas que adhieren con mayor fuerza a creencias meritocráticas tienden a percibir menos desigualdad, atribuyendo las diferencias económicas al logro personal más que a factores estructurales (Mijs, 2019; Wilson, 2003). A nivel escolar, estas creencias también legitiman una mayor desigualdad, ya que fomentan actitudes que aceptan las jerarquías sociales como justas (Batruch et al., 2022; Wiederkehr et al., 2015). Sin embargo, los conceptos e instrumentos para medir la meritocracia varían sustancialmente en la literatura. En respuesta a este problema, Castillo et al. (2023) proponen un marco conceptual y de medición para evaluar percepciones y preferencias meritocráticas y no meritocráticas, demostrando que su escala capta eficazmente estos constructos en la población adulta chilena.

Con el objetivo de contribuir a la investigación empírica sobre la formación de la meritocracia y sus factores asociados en edades tempranas (Batruch et al., 2022; Darnon et al., 2018; Wiederkehr et al., 2015), este estudio busca evaluar la aplicabilidad de dicha escala en la población escolar de Chile, un país caracterizado por una aguda y persistente desigualdad económica y un sistema educativo altamente estratificado (Chancel et al., 2022; Corvalán et al., 2017). En primer lugar, argumentamos que existe una distinción entre percepción y preferencias en meritocracia. Mientras la percepción se asocia con cómo los individuos ven el funcionamiento de los principios meritocráticos en la sociedad (lo que es), las preferencias se refieren a juicios normativos (lo que debería ser). La segunda distinción concierne a elementos meritocráticos y no meritocráticos. En este caso, también se considera que aspectos como el rol de los contactos personales y la riqueza familiar no se oponen necesariamente a la percepción y valoración del esfuerzo y el talento en la obtención de éxito y recompensas.

Para determinar hasta qué punto es posible reconocer las distintas dimensiones de la meritocracia en la población escolar, se implementará un procedimiento de análisis factorial confirmatorio utilizando datos de estudiantes chilenos. Además, se estimará la invarianza longitudinal a través de dos olas de datos de la misma cohorte para evaluar la estabilidad de la escala en el tiempo.

2 Datos, Variables y Métodos

2.1 Datos

Este estudio se basa en información proveniente de la base de datos de la Encuesta Panel sobre Educación y Meritocracia (EDUMER) para sus olas de 2023 y 2024 en estudiantes. Esta encuesta se basa en la aplicación de cuestionarios web a estudiantes de sexto básico y primero medio de nueve colegios de las regiones Metropolitana y de Valparaíso en Chile. La primera ola incluyó a 846 estudiantes (383 niñas, 418 niños, 45 identificándose como otro; $M_{edad} = 13.1$, $DE_{edad} = 1.6$), y la segunda ola siguió a 662 de ellos (302 niñas, 337 niños, 22 identificándose como otro; $M_{edad} = 14.1$, $DE_{edad} = 1.6$). La recolección de datos fue financiada por la Agencia Nacional de Investigación y Desarrollo (ANID) de Chile, bajo el proyecto FONDECYT N.º 1210847, “Meritocracia en la escuela: fundamentos morales del mercado educativo y sus implicancias para la formación ciudadana en Chile”.

2.2 Variables

Escala de Percepciones y Preferencias sobre Meritocracia: Las variables incluidas en el modelo de medición sobre percepciones y preferencias meritocráticas y no meritocráticas se operacionalizan según los mismos ítems propuestos por Castillo et al. (2023). Esta es una escala basada en dos componentes, cuatro dimensiones y ocho ítems (dos por cada dimensión). La percepción de la meritocracia se mide con dos ítems que indagan el grado de acuerdo con la afirmación de que el esfuerzo y la habilidad son recompensados en Chile, mientras que la percepción no meritocrática se mide con dos ítems que evalúan el grado de acuerdo con la idea de que el éxito está vinculado a los contactos personales y a la riqueza familiar. La preferencia por la meritocracia se mide con dos ítems que evalúan el acuerdo con la idea de que quienes se esfuerzan más o poseen más talento deberían recibir mayores recompensas. La preferencia por aspectos no meritocráticos se mide con dos indicadores que evalúan el acuerdo con la idea de que es aceptable que quienes tienen mejores contactos o padres adinerados tengan más éxito (ver Table 1). Cada ítem fue respondido en una escala Likert de cuatro puntos que va desde “muy en desacuerdo” (1) hasta “muy de acuerdo” (4).

Table 1: Ítems Meritocráticos y No Meritocráticos

Componente	Dimensión	Ítem
Percepción	Meritocrática	En Chile, las personas son recompensadas por su esfuerzo.
	Meritocrática	En Chile, las personas son recompensadas por su inteligencia y habilidades.

Table 1: Ítems Meritocráticos y No Meritocráticos

Componente	Dimensión	Ítem
Preferencia	No meritocrática	En Chile, a quienes tienen padres ricos les va mucho mejor en la vida.
	No meritocrática	En Chile, a quienes tienen buenos contactos les va mejor en la vida.
	Meritocrática	Quienes se esfuerzan más deberían recibir mayores recompensas que quienes se esfuerzan menos.
	Meritocrática	Quienes tienen más talento deberían recibir mayores recompensas que quienes tienen menos talento.
	No meritocrática	Está bien que a quienes tienen padres ricos les vaya bien en la vida.
	No meritocrática	Está bien que a quienes tienen buenos contactos les vaya bien en la vida.

2.3 Métodos

Empleamos análisis factoriales confirmatorios (AFC) basados en un modelo de medición latente de cuatro factores (Castillo et al., 2023) con un estimador de mínimos cuadrados ponderados diagonales con corrección robusta (WLSMV) debido a la naturaleza ordinal de los ítems (Kline, 2023). El ajuste del modelo se evaluó con base en los criterios propuestos por Brown (2015): CFI > 0.95; TLI > 0.95; RMSEA < 0.06.

Para examinar la estabilidad métrica del modelo de medición (Davidov et al., 2014), se realizaron pruebas de invarianza longitudinal utilizando los datos de las dos olas del estudio. En línea con Liu et al. (2017), se siguió un enfoque jerárquico con cuatro modelos: configural (estructura factorial equivalente), débil (igualdad de cargas factoriales), fuerte (igualdad de interceptos) y estricto (igualdad de varianzas de error). Este enfoque es especialmente relevante para indicadores categóricos ordenados, ya que tratar escalas Likert de cuatro puntos como continuas puede introducir sesgos en las estimaciones. Además del criterio de cambio en el chi-cuadrado, se adoptaron el cambio en CFI ($\Delta \geq -0.010$) y en RMSEA ($\Delta \geq 0.015$) como indicadores de invarianza, siguiendo las recomendaciones de Chen (2007).

3 Resultados


3.1 Descriptivos

En la Figure 1 se presenta la distribución de las respuestas para los ítems de la escala, organizadas según sus respectivas dimensiones: percepciones y preferencias. En primer lugar, en el eje de las percepciones, se observa una alta concentración de respuestas en las categorías “de acuerdo” y “muy de acuerdo” para todos los ítems, lo que indica una fuerte percepción de que los elementos evaluados influyen efectivamente en el éxito social. Esta tendencia es particularmente marcada en el ítem referido a los contactos, seguido

por el talento, y con una notable cantidad de respuestas en “muy de acuerdo” respecto al ítem padres ricos. Sin embargo, también se evidencia cierto grado de disenso: un 33,1% considera que el esfuerzo no es recompensado en la sociedad; un 28,6% no está de acuerdo con que tener padres ricos implique una ventaja; y un 26,6% manifiesta desacuerdo respecto a la influencia del talento. El menor nivel de desacuerdo se registra en el ítem de contactos.

En segundo lugar, en el eje de las preferencias, el patrón se invierte parcialmente. En el caso del esfuerzo, se observa una fuerte preferencia por que sea un criterio de recompensa, lo que contrasta con la percepción sobre su reconocimiento efectivo. En relación con el talento, un 54,6% manifiesta preferir que sea recompensado, frente a un 45,4% que no lo prefiere. En cuanto a los elementos no meritocráticos, como el origen familiar, la opinión se encuentra más dividida: en el caso de padres ricos, las respuestas se reparten casi equitativamente entre quienes prefieren y quienes no prefieren que este factor influya en el éxito. Finalmente, respecto a los contactos, se identifica una mayor proporción de respuestas que expresan preferencia por este criterio.

Figure 1: Distribución de respuestas en los ítems de Escala de Meritocracia



Fuente: Elaboración propia en base a Encuesta Panel EDUMER Ola 1 (n = 846)

En la Table 2 se presenta la matriz de correlaciones para los ítems de la escala. En términos generales, se observa una correlación positiva y de magnitud moderada entre los ítems que conforman una misma dimensión de la escala. Es decir, los ítems que miden percepción de esfuerzo y talento ($r = 0.52$, $p < .05$), así como los que miden percepción sobre padres ricos y contactos ($r = 0.61$, $p < .05$), tienden a correlacionarse entre sí. Este patrón también se reproduce en el caso de las preferencias normativas, donde los ítems dentro de cada subdimensión presentan correlaciones consistentes entre ellos.

No obstante, un hallazgo relevante es la presencia de correlaciones positivas, aunque de magnitud débil a moderada, entre ítems que pertenecen a dimensiones conceptualmente opuestas. Por ejemplo, se ob-

serva que la percepción sobre la influencia de los padres ricos—un elemento típicamente considerado no meritocrático—se asocia positivamente con la preferencia por el esfuerzo—un criterio meritocrático ($r = 0.21$). Este mismo patrón se observa con la percepción sobre el uso de contactos, que también presenta una correlación positiva con la preferencia por el esfuerzo ($r = 0.26$).

Table 2: Matriz de correlaciones policóricas entre los ítems de Escala de Meritocracia

	(A)	(B)	(C)	(D)	(E)	(F)	(G)	(H)
A. Percepción Esfuerzo								
B. Percepción Talento	0.52*							
C. Percepción Padres Ricos	-0.16	-0.04.						
D. Percepción Contactos	-0.10*	0.01*	0.61*					
E. Preferencia Esfuerzo	0.01	0.12	0.21	0.26				
F. Preferencia Talento	-0.04	0.08	0.16	0.25	0.36*			
G. Preferencia Padres Ricos	0.06	0.10	0.15	0.19	0.05	0.10		
H. Preferencia Contactos	0.11	0.09	0.06	0.26	0.06	0.12	0.61	

Note: ** $p < 0.01$, * $p < 0.5$

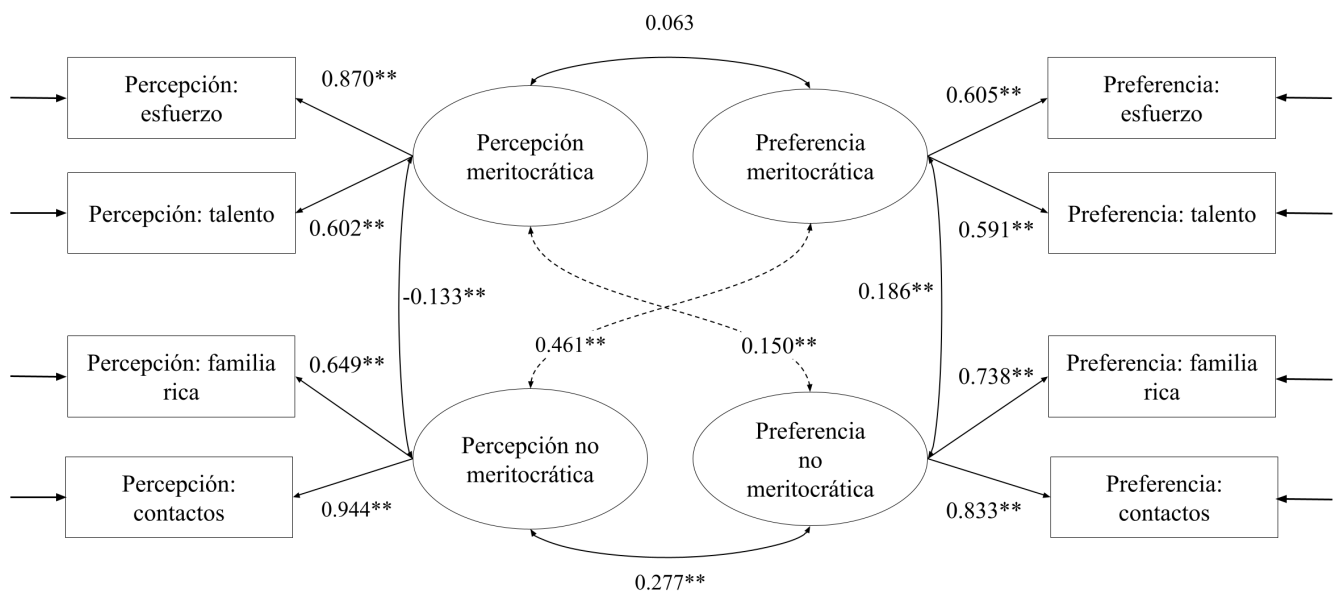
3.2 Multivariados

3.2.1 Análisis factorial confirmatorio

En la Figure 2 se presenta la solución estandarizada del modelo factorial confirmatorio estimado para la escala de meritocracia en la primera ola del estudio. De acuerdo con los grados de libertad, el modelo se encuentra sobre identificado ($df = 14 > 0$). Los indicadores de ajuste global muestran que el modelo presenta un buen ajuste a los datos empíricos. En efecto, tanto el índice de ajuste comparativo (CFI) como el índice de Tucker-Lewis (TLI) y el error cuadrático medio de aproximación (RMSEA) se encuentran dentro de los umbrales comúnmente aceptados para indicar un buen ajuste (CFI y TLI > 0.95 ; RMSEA < 0.05), lo cual respalda la validez factorial del instrumento (Brown, 2015).

En relación con las cargas factoriales, todos los ítems se asocian de forma positiva y estadísticamente significativa con sus respectivas dimensiones latentes, y presentan cargas estandarizadas superiores a 0.5, lo que indica una adecuada calidad de la medición (Brown, 2015). Dentro de la dimensión de percepción meritocrática, el ítem correspondiente al esfuerzo destaca como el indicador con mayor carga factorial ($\beta = 0.87$, $p < 0.01$), lo que sugiere que este principio constituye el eje central en las creencias sobre los mecanismos legítimos del éxito social desde una lógica meritocrática. Por su parte, en la dimensión de percepción no meritocrática, el ítem referido al uso de contactos personales presenta la mayor carga ($\beta = 0.944$, $p < 0.01$), posicionándose como el componente más representativo de esta dimensión. En las dimensiones normativas se observan patrones similares: en la preferencia por criterios meritocráticos existe una cierta paridad entre los ítems de esfuerzo y talento, sin que uno predomine claramente sobre el

Figure 2: Análisis factorial confirmatorio de Escala de Meritocracia Ola 1



DWLS Estimation, completely standardized solution, N=846
Chi2=40.288* / df=14, CFI=0.989, TLI=0.978, RMSEA=0.047**
**** $p < 0.01$, * $p < 0.05$**

otro, mientras que en la preferencia por criterios no meritocráticos nuevamente el uso de contactos ($\beta = 0.833$, $p < 0.01$) emerge como el criterio normativo más relevante.

Respecto de las correlaciones entre factores, se identifican relaciones conceptualmente significativas. Por un lado, la percepción de que los logros sociales se deben a factores meritocráticos se asocia negativamente con la percepción de que estos se explican por mecanismos no meritocráticos ($r = -0.133$, $p < 0.01$). Por otro lado, y en contraste con esta lógica excluyente en el plano perceptivo, se observa una correlación positiva entre las preferencias meritocráticas y no meritocráticas ($r = 0.186$, $p < 0.01$). Este hallazgo sugiere que, normativamente, ambas lógicas pueden coexistir: los estudiantes pueden simultáneamente valorar que el esfuerzo o el talento deban ser recompensados, al mismo tiempo que consideran legítimo que otros factores, como el origen familiar o los contactos, también influyan en el acceso a ventajas.

Se observa una correlación positiva entre la percepción de mecanismos no meritocráticos y la preferencia por mecanismos meritocráticos. Específicamente, quienes perciben que el funcionamiento social se basa en factores no meritocráticos —como los contactos personales o el origen familiar— tienden a manifestar una mayor preferencia por que elementos meritocráticos, como el esfuerzo y el talento, sean efectivamente recompensados en la sociedad ($r = 0.461$, $p < 0.01$). Este hallazgo sugiere que el reconocimiento de una realidad social percibida como injusta o alejada del ideal meritocrático puede reforzar normativamente la adhesión a principios meritocráticos. En otras palabras, cuanto más se percibe que operan criterios ajenos al mérito en la distribución de ventajas, mayor es el deseo de que el mérito —en particular, el esfuerzo y el talento— se convierta en el fundamento legítimo de la recompensa social.

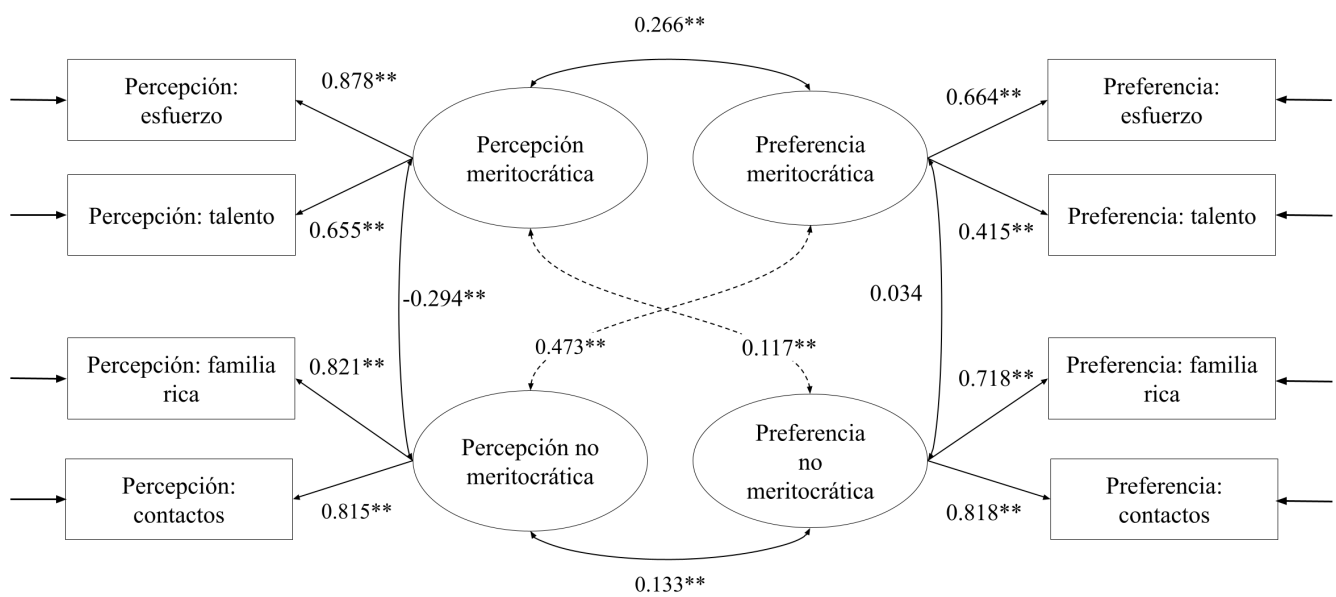
En la [Figure 3](#) se presenta la solución estandarizada del modelo factorial confirmatorio estimado para la segunda ola del estudio. Al igual que en la ola anterior, el modelo se encuentra sobreidentificado, con 14 grados de libertad ($df = 14 > 0$), lo que permite una estimación robusta de los parámetros del modelo.

En términos de ajuste global, los indicadores complementarios —el índice de ajuste comparativo (CFI) y el índice de Tucker-Lewis (TLI)— se sitúan por sobre el umbral de 0.95, lo que indica un buen ajuste relativo del modelo. Por su parte, el RMSEA alcanza un valor de 0.06, que corresponde a un ajuste razonable según los criterios establecidos en la literatura especializada ([Brown, 2015](#)).

En cuanto a las cargas factoriales, se mantienen los patrones observados en la ola anterior con algunas variaciones menores. Dentro de la dimensión de percepción meritocrática, el ítem de esfuerzo continúa siendo el más relevante, mostrando una carga superior a la del talento. En la percepción no meritocrática, en cambio, se observa una mayor paridad entre los indicadores: tanto el ítem de padres ricos como el de contactos personales contribuyen de manera similar a la dimensión. En lo que respecta a las preferencias normativas, se confirma nuevamente que el esfuerzo es el componente con mayor carga factorial dentro de la dimensión meritocrática, superando al talento. Por su parte, en la preferencia por criterios no meritocráticos, el ítem que presenta mayor peso es el de contactos, reafirmando su centralidad en esta dimensión.

Respecto de las correlaciones entre factores, se replican en gran medida los patrones observados en la primera ola. Se mantiene la correlación negativa entre percepción meritocrática y percepción no meritocrática, así como la correlación positiva entre las preferencias por criterios meritocráticos y no meri-

Figure 3: Análisis factorial confirmatorio de Escala de Meritocracia Ola 2



DWLS Estimation, completely standardized solution, N=662
Chi2=50.600* / df=14, CFI=0.983, TLI=0.966, RMSEA=0.063**
**** $p < 0.01$, * $p < 0.05$**

tocráticos, indicando la persistencia de una tensión entre representación descriptiva y posicionamiento normativo. También se conserva la asociación positiva entre percepción no meritocrática y preferencia por estos mecanismos, lo que refuerza la hipótesis de legitimación normativa de estructuras no basadas en mérito.

3.2.2 Invarianza longitudinal

Para evaluar la estabilidad estructural de la escala a lo largo del tiempo, se estimaron modelos jerárquicos de invarianza longitudinal utilizando análisis factorial confirmatorio (CFA) con indicadores categóricos ordenados. En línea con las recomendaciones metodológicas de Liu et al. (2017), se evaluaron cuatro modelos anidados con estimación mediante mínimos cuadrados ponderados diagonales con corrección robusta (WLSMV) y parametrización tipo theta. Los modelos probados fueron: configural (estructura factorial libre), débil (cargas factoriales iguales), fuerte (cargas y umbrales iguales), y estricto (cargas, umbrales y varianzas residuales iguales).

El modelo especificado contempla cuatro factores latentes replicados en dos mediciones (olas), cada uno con dos ítems. Se permitió la covarianza de los errores de medición del mismo ítem entre las dos olas, una práctica recomendada para modelos longitudinales con pocos indicadores por factor. La identificación se logró fijando una carga a 1 por cada factor y un umbral igualado por ítem entre olas.

Table 3: Pruebas de invarianza longitudinal para el modelo de cuatro factores con indicadores ordinales

Model	χ^2 (df)	CFI	RMSEA (90 CI)	$\Delta\chi^2$ (Δ df)	Δ CFI	Δ RMSEA	Decision
Configural	117.7 (68)	0.991	0.035 (0.024-0.046)	0 (0)	0	0.000	Reference
Weak	122.51 (72)	0.990	0.034 (0.024-0.045)	4.809 (4)	0	-0.001	Accept
Strong	128.53 (80)	0.991	0.032 (0.021-0.042)	6.02 (8)	0	-0.002	Accept
Strict	130.17 (84)	0.991	0.031 (0.02-0.04)	1.635 (4)	0	-0.002	Accept

En la Table 3 se presentan los índices de ajuste global para cada modelo, junto con las diferencias relativas entre modelos consecutivos. Los valores de $CFI \geq 0.990$ y $RMSEA \leq 0.035$ en todos los modelos sugieren un ajuste adecuado. Además, los cambios entre modelos anidados fueron sistemáticamente inferiores a los puntos de corte recomendados para evaluar deterioro del ajuste ($\Delta CFI < 0.01$; $\Delta RMSEA < 0.015$), lo que respalda la aceptación de los supuestos de invarianza en cada nivel.

En conjunto, estos resultados respaldan la existencia de invarianza estricta longitudinal, lo que permite comparar de manera válida las puntuaciones latentes entre las dos olas del estudio. Esto implica que los cambios observados pueden atribuirse a diferencias reales en las percepciones y preferencias meritocráticas de los estudiantes, y no a cambios en la interpretación o funcionamiento de los ítems a lo largo del tiempo.

4 Referencias

Batruch, A., Jetten, J., Van de Werfhorst, H., Darnon, C., & Butera, F. (2022). Belief in School Meritocracy and the Legitimization of Social and Income Inequality. *Social Psychological and Personality*

- Science*, 194855062211110. <https://doi.org/10.1177/19485506221111017>
- Brown, T. A. (2015). *Confirmatory factor analysis for applied research* (Second edition). New York London: The Guilford Press.
- Castillo, J. C., Iturra, J., Maldonado, L., Atria, J., & Meneses, F. (2023). A Multidimensional Approach for Measuring Meritocratic Beliefs: Advantages, Limitations and Alternatives to the ISSP Social Inequality Survey. *International Journal of Sociology*, 53(6), 448–472. <https://doi.org/10.1080/00207659.2023.2274712>
- Chancel, L., Piketty, T., Saez, E., & Zucman, G. (2022). World inequality report 2022. <https://bibliotecadigital.ccb.org>
- Chen, F. F. (2007). Sensitivity of Goodness of Fit Indexes to Lack of Measurement Invariance. *Structural Equation Modeling: A Multidisciplinary Journal*, 14(3), 464–504. <https://doi.org/10.1080/10705510701301834>
- Corvalán, J., Carrasco, A., & García-Huidobro, J. E. (2017). *Mercado escolar: Libertad, diversidad y desigualdad*. Ediciones UC.
- Darnon, C., Wiederkehr, V., Dompnier, B., & Martinot, D. (2018). “Where there is a will, there is a way”: Belief in school meritocracy and the social-class achievement gap. *British Journal of Social Psychology*, 57(1), 250–262. <https://doi.org/10.1111/bjso.12214>
- Davidov, E., Meuleman, B., Cieciuch, J., Schmidt, P., & Billiet, J. (2014). Measurement Equivalence in Cross-National Research. *Annual Review of Sociology*, 40(Volume 40, 2014), 55–75. <https://doi.org/10.1146/annurev-soc-071913-043137>
- Dubet, F. (2011). *Repensar la justicia social* (Sexta Edición). Siglo XXI.
- Kline, R. B. (2023). *Principles and Practice of Structural Equation Modeling*. Guilford Publications.
- Liu, Y., Millsap, R. E., West, S. G., Tein, J.-Y., Tanaka, R., & Grimm, K. J. (2017). Testing measurement invariance in longitudinal data with ordered-categorical measures. *Psychological Methods*, 22(3), 486–506. <https://doi.org/10.1037/met0000075>
- Mijs, J. (2019). The paradox of inequality: Income inequality and belief in meritocracy go hand in hand. *Socio-Economic Review*, 19(1), 7–35. <https://doi.org/10.1093/ser/mwy051>
- Wiederkehr, V., Bonnot, V., Krauth-Gruber, S., & Darnon, C. (2015). Belief in school meritocracy as a system-justifying tool for low status students. *Frontiers in Psychology*, 6.
- Wilson, C. (2003). The Role of a Merit Principle in Distributive Justice. *The Journal of Ethics*, 7(3), 277–314. <https://doi.org/10.1023/A:1024667228488>
- Young, M. (1958). *The rise of the meritocracy*. New Brunswick, N.J., U.S.A: Transaction Publishers.

5 Anexos

5.1 Análisis factorial exploratorio

```
tab_fa(db_w1, method = "ml", rotation = "varimax", show.comm = TRUE)
```

Parallel analysis suggests that the number of factors = 4 and the number of components =

Table 4: Análisis exploratorio escala de meritocracia

Table 4: Factor Analysis					
	Factor 1	Factor 2	Factor 3	Factor 4	Communality
En Chile, las personas son recompensadas por sus esfuerzos	0.07	-0.09	0.59	-0.04	0.36
En Chile, las personas son recompensadas por su inteligencia y habilidad	0.04	0.02	0.76	0.12	0.60
En Chile, a quienes tienen padres ricos les va mucho mejor en la vida	0.04	0.99	-0.07	0.12	0.99
En Chile, quienes tienen buenos contactos les va mejor en la vida	0.20	0.49	-0.04	0.30	0.37

Quienes más se esfuerzan deberían obtener mayores recompensas que quienes se esfuerzan menos	0.01	0.12	0.06	0.47	0.24
Quienes poseen más talento deberían obtener mayores recompensas que quienes poseen menos talento	0.07	0.07	-0.01	0.57	0.33
Está bien que quienes tienen padres ricos les vaya bien en la vida	0.53	0.12	0.07	0.05	0.31
Está bien que quienes tienen buenos contactos les vaya bien en la vida	0.99	0.01	0.05	0.07	0.99
Total					4.19
Communalities					
Cronbach's α	0.70	0.69	0.61	0.43	

Como primera parte del análisis, se aplicó la adecuación muestral (KMO), dando como resultado correlaciones de magnitud moderada de manera generalizada (Ver anexos). Esto quiere decir que los resultados son adecuados para realizar un Análisis Factorial Exploratorio. Además se aplicó un test de esfericidad de Bartlett el cual dio significancia estadística, por lo que se puede afirmar que la matriz de correlaciones observada es una matriz identidad ($p < .05$).

En la Table 4 se pueden observar los resultados del análisis factorial exploratorio realizado a partir del método Maximum likelihood con una rotación ortogonal. Se puede observar la presencia de cuatro factores, pero resultan llamativos los factores 1 y 2, específicamente las cargas factoriales de preferencia de contactos y la percepción de padres ricos, respectivamente. Ambos indicadores tienen una carga factorial de 0.99 y una comunalidad del mismo valor. Su interpretación sugiere que ambos indicadores se asocian casi por completo a un factor, por lo que el indicador con menor carga factorial en los factores 1 y 2 podría ser prescindido. No obstante, este resultado que debe tomarse con precaución, puesto que el método para la extracción de factores empleado fue ML, el cual tiende a maximizar la probabilidad de que los parámetros reproduzcan los parámetros observados, por lo que podría haber generado algún tipo de sobreajuste.

Por otro lado, al aplicar el método de Ejes Principales, las cargas factoriales de 0.99 que se generaban en el caso anterior disminuyen, pero aún así mantienen una alta communalidad. Es importante mencionar que todos los indicadores poseen una complejidad > 1 , lo cual señala que cada ítem representa un único constructo subyacente. Por último, la suma de cargas al cuadrado para los dos primeros factores es > 1 , por lo que son factores que vale la pena conservar. En cambio, los factores 3 y 4 poseen valores < 1 (0.913 y 0.631, respectivamente), lo cual resulta problemático para la escala analizada. Si bien, en términos de conveniencia estadística sería mejor eliminar el factor 4 de la escala, esto no puede realizarse debido a la relevancia teórica que posee para el instrumento de medición, por ello es importante tomar en consideración este resultado para posteriores usos.

```
KMO(corMat)
```

Kaiser-Meyer-Olkin factor adequacy

Call: `KMO(r = corMat)`

Overall MSA = 0.56

MSA for each item =

perc_effort	perc_talent	perc_rich_parents	perc_contact
0.52	0.52	0.55	0.59
pref_effort	pref_talent	pref_rich_parents	pref_contact
0.67	0.67	0.55	0.52

```
cortest.bartlett(corMat, n = 846)
```

\$chisq

```
[1] 986.5685
```

\$p.value

[illegible] $\$df$


[1] 28

Factor analysis results

	Factor_1	Factor_2	Factor_3	Factor_4	Communality	Uniqueness	Complexity
pref_contact	0.919	-0.024	-0.005	0.002	0.84	0.16	1.00
pref_rich_parents	0.576	0.096	0.035	-0.028	0.36	0.64	1.07
perc_rich_parents	-0.030	0.868	-0.005	-0.034	0.73	0.27	1.01
perc_contact	0.134	0.547	-0.007	0.162	0.44	0.56	1.30
perc_talent	-0.014	0.036	0.672	0.077	0.46	0.54	1.03
perc_effort	0.021	-0.047	0.670	-0.075	0.46	0.54	1.04
pref_talent	0.015	-0.027	-0.028	0.590	0.34	0.66	1.01
pref_effort	-0.058	0.060	0.072	0.466	0.24	0.76	1.11

```
scree.plot(db_w1)
```

Figure 4: Gráfico de sedimentación



```
fac_pa_t<-fa_table(fac_pa)
fac_pa_t$ind_table
```

```
fac_pa_t$f_table
```

Eigenvalues, Variance Explained, and Factor Correlations for Rotated Factor Solution

Property	Factor_1	Factor_2	Factor_3	Factor_4
SS loadings	1.209	1.108	0.913	0.631
Proportion Var	0.151	0.138	0.114	0.079
Cumulative Var	0.151	0.290	0.404	0.483
Proportion Explained	0.313	0.287	0.236	0.163
Cumulative Proportion	0.313	0.600	0.837	1.000
Factor_1	1.000	0.146	0.144	0.196
Factor_2	0.146	1.000	-0.111	0.364
Factor_3	0.144	-0.111	1.000	0.072
Factor_4	0.196	0.364	0.072	1.000

6 Código de R

```
library(knitr)
knitr::opts_chunk$set(echo = TRUE, include = TRUE, warning = FALSE, message = FALSE)

table_format <- if(is_html_output()) {
  "html"
} else if(is_latex_output()) {
  "latex"
}
table_format2 <- if(is_html_output()) {
  T
} else if(is_latex_output()) {
  F
}

options(kableExtra.html.bsTable = T)
options(knitr.kable.NA = "")
if (! require("pacman")) install.packages("pacman")

pacman::p_load(tidyverse,
               sjmisc,
               sjPlot,
               here,
               lavaan,
               devtools,
               psych,
               psy,
```

```

        corrplot,
        ggdist,
        GPArrotations,
        ggrepel,
        nfactors,
        patchwork,
        sjlabelled,
        semTools,
        gtools,
        RColorBrewer,
        skimr,
        readxl,
        tydiverse,
        kableExtra,
        xtable)

options(scipen=999)
rm(list = ls())
load(file = here("output", "data", "db_long_proc.RData"))

names(db_long)
glimpse(db_long)

tabla_merit <- data.frame(
  Componente = c("Percepción", "", "", "",
                 "Preferencia", "", "", ""),
  Dimensión = c("Meritocrática", "Meritocrática",
                "No meritocrática", "No meritocrática",
                "Meritocrática", "Meritocrática",
                "No meritocrática", "No meritocrática"),
  Ítem = c(
    "En Chile, las personas son recompensadas por su esfuerzo.",
    "En Chile, las personas son recompensadas por su inteligencia y habilidades.",
    "En Chile, a quienes tienen padres ricos les va mucho mejor en la vida.",
    "En Chile, a quienes tienen buenos contactos les va mejor en la vida.",
    "Quienes se esfuerzan más deberían recibir mayores recompensas que quienes se esfuerzan",
    "Quienes tienen más talento deberían recibir mayores recompensas que quienes tienen me",
    "Está bien que a quienes tienen padres ricos les vaya bien en la vida.",

```



```

    "Está bien que a quienes tienen buenos contactos les vaya bien en la vida."
  )
)

tabla_merit %>% kableExtra::kable(., format = "markdown")

theme_set(theme_ggdist())
colors <- RColorBrewer::brewer.pal(n = 4, name = "RdBu")

a <- db_long %>%
  filter(ola == 1) %>%
  select(starts_with("perc")) %>%
  sjPlot::plot_likert(geom.colors = colors,
                      title = c("a. Percepciones"),
                      geom.size = 0.8,
                      axis.labels = c("Esfuerzo", "Talento", "Padres ricos", "Contactos"),
                      catcount = 4,
                      values = "sum.outside",
                      reverse.colors = F,
                      reverse.scale = T,
                      show.n = FALSE,
                      show.prc.sign = T
                    ) +
  ggplot2::theme(legend.position = "none")

b <- db_long %>%
  filter(ola == 1) %>%
  select(starts_with("pref")) %>%
  sjPlot::plot_likert(geom.colors = colors,
                      title = c("b. Preferencias"),
                      geom.size = 0.8,
                      axis.labels = c("Esfuerzo", "Talento", "Padres ricos", "Contactos"),
                      catcount = 4,
                      values = "sum.outside",
                      reverse.colors = F,
                      reverse.scale = T,
                      show.n = FALSE,
                      show.prc.sign = T
                    ) +
  ggplot2::theme(legend.position = "bottom")

```

```

likerplot <- a / b + plot_annotation(caption = paste0("Fuente: Elaboración propia en base a
"))

likerplot

M <- psych::polychoric(db_long[db_long$ola==1,][c(4:11)])

diag(M$rho) <- NA

rownames(M$rho) <- c("A. Percepción Esfuerzo",
                    "B. Percepción Talento",
                    "C. Percepción Padres Ricos",
                    "D. Percepción Contactos",
                    "E. Preferencia Esfuerzo",
                    "F. Preferencia Talento",
                    "G. Preferencia Padres Ricos",
                    "H. Preferencia Contactos")

#set Column names of the matrix
colnames(M$rho) <-c("(A)", "(B)", "(C)", "(D)", "(E)", "(F)", "(G)",
                    "(H)")

testp <- cor.mtest(M$rho, conf.level = 0.95)

df <- as.data.frame(M$rho)

mat_cor <- as.matrix(df)

p_stars <- gtools::stars.pval(testp$p)

mat_cor_rounded <- round(mat_cor, 2)
mat_cor_char <- format(mat_cor_rounded, nsmall = 2)

cor_with_stars <- ifelse(is.na(mat_cor_char), "",
                        paste0(mat_cor_char, p_stars))

cor_with_stars[upper.tri(cor_with_stars, diag = TRUE)] <- NA

```

```

cor_with_stars %>%
  kableExtra::kable(., format = "markdown") %>%
  kableExtra::add_footnote(label = "**p<0.01, *p<0.5", notation = "none")

# model
model_cfa <- '
  perc_merit = ~ perc_effort + perc_talent
  perc_nmerit = ~ perc_rich_parents + perc_contact
  pref_merit = ~ pref_effort + pref_talent
  pref_nmerit = ~ pref_rich_parents + pref_contact
  '

# estimation for each order set

m1_cfa <- cfa(model = model_cfa,
              data = subset(db_long, ola == 1),
              estimator = "DWLS",
              ordered = T,
              std.lv = F)

m2_cfa <- cfa(model = model_cfa,
              data = subset(db_long, ola == 2),
              estimator = "DWLS",
              ordered = T,
              std.lv = F)

knitr::include_graphics(path = here("sem/cfa_w1.png"))
knitr::include_graphics(path = here("sem/cfa_w2.png"))
load(file = here("output", "data", "db_long_proc.RData"))

names(db_long)
glimpse(db_long)
dim(db_long)
db_invariance <-
  db_long %>%
  select(id_estudiante, ola, starts_with(c("perc", "pref"))) %>%
  pivot_wider(

```

```

    id_cols = id_estudiante,
    names_from = ola,
    names_glue = "{.value}{ola}",
    values_from = c(
      perc_effort, perc_talent,
      perc_rich_parents, perc_contact,
      pref_effort, pref_talent,
      pref_rich_parents, pref_contact
    )
  ) %>%
na.omit() %>%
rename_with(~ str_replace_all(., "_", ""))

db_invariance <- db_invariance %>%
  mutate(
    across(
      .cols = -idestudiante,
      .fns = ~ case_when(. == 1 ~ 0,
                          . == 2 ~ 1,
                          . == 3 ~ 2,
                          . == 4 ~ 3)
    )
  )

db_invariance <- db_invariance %>%
  mutate(
    across(
      .cols = -idestudiante,
      .fns = ~ ordered(.)
    )
  )

baseline_model_smt <- ('

#####
# Definición de factores (1 marcador por factor)
#####

percmerit1  =~ 1*perceffort1      + perctalent1
percmerit2  =~ 1*perceffort2      + perctalent2

```

```

percnmerit1 =~ 1*percrichparents1 + percontact1
percnmerit2 =~ 1*percrichparents2 + percontact2

prefmerit1  =~ 1*prefeffort1      + preftalent1
prefmerit2  =~ 1*prefeffort2      + preftalent2

prefnmerit1 =~ 1*prefrichparents1 + prefcontact1
prefnmerit2 =~ 1*prefrichparents2 + prefcontact2

#####
# Covarianzas entre errores (mismo ítem, distintas olas)
#####

perceffort1 ~~ perceffort2
perctalent1 ~~ perctalent2

percrichparents1 ~~ percrichparents2
percontact1      ~~ percontact2

prefeffort1 ~~ prefeffort2
preftalent1  ~~ preftalent2

prefrichparents1 ~~ prefrichparents2
prefcontact1    ~~ prefcontact2
')

# Estimación del modelo
fit_baseline <- cfa(baseline_model_smt, data = db_invariance,
                    ordered = c("perceffort1", "perctalent1", "perceffort2", "perctalent2",
                                "percrichparents1", "percontact1", "percrichparents2", "percontact2",
                                "prefeffort1", "preftalent1", "prefeffort2", "preftalent2",
                                "prefrichparents1", "prefcontact1", "prefrichparents2", "prefcontact2"),
                    parameterization = "theta",
                    estimator = "WLSMV")

loadinginv_model_smt <- ('

```

```

# Igualación de cargas (invarianza débil)

percmerit1 =~ 1*perceffort1 + pe_loading*perctalent1
percmerit2 =~ 1*perceffort2 + pe_loading*perctalent2

percnmerit1 =~ 1*percrichparents1 + prc_loading*percccontact1
percnmerit2 =~ 1*percrichparents2 + prc_loading*percccontact2

prefmerit1 =~ 1*prefeffort1 + pfe_loading*preftalent1
prefmerit2 =~ 1*prefeffort2 + pfe_loading*preftalent2

prefnmerit1 =~ 1*prefrichparents1 + pfrc_loading*prefcontact1
prefnmerit2 =~ 1*prefrichparents2 + pfrc_loading*prefcontact2


# Varianzas y covarianzas latentes

percmerit1 ~~ percmerit1 + percmerit2
percmerit2 ~~ percmerit2
percnmerit1 ~~ percnmerit1 + percnmerit2
percnmerit2 ~~ percnmerit2
prefmerit1 ~~ prefmerit1 + prefmerit2
prefmerit2 ~~ prefmerit2
prefnmerit1 ~~ prefnmerit1 + prefnmerit2
prefnmerit2 ~~ prefnmerit2


# Umbrales (uno igualado por ítem)

# perceffort1 | pe1t1*t1 + pe1t2*t2
# perceffort2 | pe2t1*t1 + pe2t2*t2
# perctalent1 | pt1t1*t1 + pt1t2*t2
# perctalent2 | pt2t1*t1 + pt2t2*t2
# percrichparents1 | prp1t1*t1 + prp1t2*t2
# percrichparents2 | prp2t1*t1 + prp2t2*t2
# percccontact1 | pc1t1*t1 + pc1t2*t2
# percccontact2 | pc2t1*t1 + pc2t2*t2
# prefefort1 | pre1t1*t1 + pre1t2*t2
# prefefort2 | pre2t1*t1 + pre2t2*t2
# preftalent1 | prt1t1*t1 + prt1t2*t2

```

```

# preftalent2 | prt2t1*t1 + prt2t2*t2
# prefrichparents1 | pfrp1t1*t1 + pfrp1t2*t2
# prefrichparents2 | pfrp2t1*t1 + pfrp2t2*t2
# prefcontact1 | pfc1t1*t1 + pfc1t2*t2
# prefcontact2 | pfc2t1*t1 + pfc2t2*t2

# Covarianzas entre errores

perceffort1 ~~ perceffort2
perctalent1 ~~ perctalent2
percrichparents1 ~~ percrichparents2
perccontact1 ~~ perccontact2
prefeffort1 ~~ prefeffort2
preftalent1 ~~ preftalent2
prefrichparents1 ~~ prefrichparents2
prefcontact1 ~~ prefcontact2
')

fit_loadinginv <- cfa(loadinginv_model_smt, data = db_invariance,
                      ordered = c("perceffort1", "perctalent1", "perceffort2", "perctalent2",
                                   "percrichparents1", "perccontact1", "percrichparents2",
                                   "prefeffort1", "preftalent1", "prefeffort2", "preftalent2",
                                   "prefrichparents1", "prefcontact1", "prefrichparents2",
                                   parameterization = "theta",
                                   estimator = "WLSMV")

thresholdinv_model_smt <- ('

# Igualación de cargas (como en el modelo débil)

percmerit1  =~ 1*perceffort1 + pe_loading*perctalent1
percmerit2  =~ 1*perceffort2 + pe_loading*perctalent2

percnmerit1 =~ 1*percrichparents1 + prc_loading*perccontact1
percnmerit2 =~ 1*percrichparents2 + prc_loading*perccontact2

prefmerit1  =~ 1*prefeffort1 + pfe_loading*preftalent1
prefmerit2  =~ 1*prefeffort2 + pfe_loading*preftalent2

```

```

prefnmerit1 =~ 1*prefrichparents1 + pfrc_loading*prefcontact1
prefnmerit2 =~ 1*prefrichparents2 + pfrc_loading*prefcontact2

# Varianzas y covarianzas latentes

percmerit1  ~~ percmerit1 + percmerit2
percmerit2  ~~ percmerit2
percnmerit1 ~~ percnmerit1 + percnmerit2
percnmerit2 ~~ percnmerit2
prefmerit1  ~~ prefmerit1 + prefmerit2
prefmerit2  ~~ prefmerit2
prefnmerit1 ~~ prefnmerit1 + prefnmerit2
prefnmerit2 ~~ prefnmerit2

# Thresholds iguales entre olas (invarianza fuerte)

perceffort1      | pe_t1*t1 + pe_t2*t2
perceffort2      | pe_t1*t1 + pe_t2*t2
perctalent1      | pt_t1*t1 + pt_t2*t2
perctalent2      | pt_t1*t1 + pt_t2*t2
percrichparents1| prp_t1*t1 + prp_t2*t2
percrichparents2| prp_t1*t1 + prp_t2*t2
perccontact1     | pc_t1*t1 + pc_t2*t2
perccontact2     | pc_t1*t1 + pc_t2*t2
prefeffort1      | pre_t1*t1 + pre_t2*t2
prefeffort2      | pre_t1*t1 + pre_t2*t2
preftalent1      | prt_t1*t1 + prt_t2*t2
preftalent2      | prt_t1*t1 + prt_t2*t2
prefrichparents1| pfrp_t1*t1 + pfrp_t2*t2
prefrichparents2| pfrp_t1*t1 + pfrp_t2*t2
prefcontact1     | pfc_t1*t1 + pfc_t2*t2
prefcontact2     | pfc_t1*t1 + pfc_t2*t2

# Interceptos fijos

perceffort1 + perctalent1 ~ 0*1
perceffort2 + perctalent2 ~ 0*1

```



```

percrichparents1 + percontact1 ~ 0*1
percrichparents2 + percontact2 ~ 0*1
preffort1 + preftalent1 ~ 0*1
preffort2 + preftalent2 ~ 0*1
prefrichparents1 + precontact1 ~ 0*1
prefrichparents2 + precontact2 ~ 0*1

# Varianzas únicas

perceffort1 ~~ 1*perceffort1
perctalent1 ~~ 1*perctalent1
percrichparents1 ~~ 1*percrichparents1
percontact1 ~~ 1*percontact1
preffort1 ~~ 1*preffort1
preftalent1 ~~ 1*preftalent1
prefrichparents1 ~~ 1*prefrichparents1
precontact1 ~~ 1*precontact1

perceffort2 ~~ NA*perceffort2
perctalent2 ~~ NA*perctalent2
percrichparents2 ~~ NA*percrichparents2
percontact2 ~~ NA*percontact2
preffort2 ~~ NA*preffort2
preftalent2 ~~ NA*preftalent2
prefrichparents2 ~~ NA*prefrichparents2
precontact2 ~~ NA*precontact2

# Covarianzas entre errores longitudinales

perceffort1 ~~ perceffort2
perctalent1 ~~ perctalent2
percrichparents1 ~~ percrichparents2
percontact1 ~~ percontact2
preffort1 ~~ preffort2
preftalent1 ~~ preftalent2
prefrichparents1 ~~ prefrichparents2
precontact1 ~~ precontact2
')
```

```

fit_thresholdinv <- cfa(thresholdinv_model_smt, data = db_invariance,
                        ordered = c("perceffort1", "perctalent1", "perceffort2", "perctalent2",
                                     "percrichparents1", "perccontact1", "percrichparents2",
                                     "prefeffort1", "preftalent1", "prefeffort2", "preftalent2",
                                     "prefrichparents1", "prefcontact1", "prefrichparents2"),
                        parameterization = "theta",
                        estimator = "WLSMV")

uniquenessinv_model_smt <- ('

# Cargas factoriales (invarianza débil)

percmerit1 =~ 1*perceffort1 + pe_loading*perctalent1
percmerit2 =~ 1*perceffort2 + pe_loading*perctalent2

percnmerit1 =~ 1*percrichparents1 + prc_loading*perccontact1
percnmerit2 =~ 1*percrichparents2 + prc_loading*perccontact2

prefmerit1 =~ 1*preeffort1 + pfe_loading*preftalent1
prefmerit2 =~ 1*preeffort2 + pfe_loading*preftalent2

prefnmerit1 =~ 1*prefrichparents1 + pfrc_loading*prefcontact1
prefnmerit2 =~ 1*prefrichparents2 + pfrc_loading*prefcontact2

# Varianzas y covarianzas de factores latentes

percmerit1 ~~ percmerit1 + percmerit2
percmerit2 ~~ percmerit2
percnmerit1 ~~ percnmerit1 + percnmerit2
percnmerit2 ~~ percnmerit2
prefmerit1 ~~ prefmerit1 + prefmerit2
prefmerit2 ~~ prefmerit2
prefnmerit1 ~~ prefnmerit1 + prefnmerit2
prefnmerit2 ~~ prefnmerit2

# Medias latentes

percmerit1 ~ 0*1

```

```

percmerit2 ~ 1
percnmerit1 ~ 0*1
percnmerit2 ~ 1
prefmerit1 ~ 0*1
prefmerit2 ~ 1
prefnmerit1 ~ 0*1
prefnmerit2 ~ 1

# Umbrales (invarianza fuerte)

perceffort1      | pe_t1*t1 + pe_t2*t2
perceffort2      | pe_t1*t1 + pe_t2*t2
perctalent1      | pt_t1*t1 + pt_t2*t2
perctalent2      | pt_t1*t1 + pt_t2*t2
percrichparents1| prp_t1*t1 + prp_t2*t2
percrichparents2| prp_t1*t1 + prp_t2*t2
perccontact1     | pc_t1*t1 + pc_t2*t2
perccontact2     | pc_t1*t1 + pc_t2*t2
prefeffort1      | pre_t1*t1 + pre_t2*t2
prefeffort2      | pre_t1*t1 + pre_t2*t2
preftalent1      | prt_t1*t1 + prt_t2*t2
preftalent2      | prt_t1*t1 + prt_t2*t2
prefrichparents1| pfrp_t1*t1 + pfrp_t2*t2
prefrichparents2| pfrp_t1*t1 + pfrp_t2*t2
prefcontact1     | pfc_t1*t1 + pfc_t2*t2
prefcontact2     | pfc_t1*t1 + pfc_t2*t2

# Interceptos fijos

perceffort1 + perctalent1 ~ 0*1
perceffort2 + perctalent2 ~ 0*1
percrichparents1 + perccontact1 ~ 0*1
percrichparents2 + perccontact2 ~ 0*1
prefeffort1 + preftalent1 ~ 0*1
prefeffort2 + preftalent2 ~ 0*1
prefrichparents1 + prefcontact1 ~ 0*1
prefrichparents2 + prefcontact2 ~ 0*1

```

```

# Varianzas únicas (invarianza estricta)
# Fijadas a 1 en todas las olas

perceffort1 ~~ 1*perceffort1
perceffort2 ~~ 1*perceffort2
perctalent1 ~~ 1*perctalent1
perctalent2 ~~ 1*perctalent2

percrichparents1 ~~ 1*percrichparents1
percrichparents2 ~~ 1*percrichparents2
percontact1 ~~ 1*percontact1
percontact2 ~~ 1*percontact2

prefeffort1 ~~ 1*prefeffort1
prefeffort2 ~~ 1*prefeffort2
preftalent1 ~~ 1*preftalent1
preftalent2 ~~ 1*preftalent2

prefrichparents1 ~~ 1*prefrichparents1
prefrichparents2 ~~ 1*prefrichparents2
prefcontact1 ~~ 1*prefcontact1
prefcontact2 ~~ 1*prefcontact2

# Covarianzas entre errores (mismo ítem, diferente ola)

perceffort1 ~~ perceffort2
perctalent1 ~~ perctalent2
percrichparents1 ~~ percrichparents2
percontact1 ~~ percontact2
prefeffort1 ~~ prefeffort2
preftalent1 ~~ preftalent2
prefrichparents1 ~~ prefrichparents2
prefcontact1 ~~ prefcontact2
')

fit_uniquenessinv <- cfa(uniquenessinv_model_smt, data = db_invariance,
                        ordered = c("perceffort1", "perctalent1", "perceffort2", "perctal
                                "percrichparents1", "percontact1", "percrichparents2
                                "prefeffort1", "preftalent1", "prefeffort2", "preftal

```

```

        "prefrichparents1", "prefcontact1", "prefrichparents2",
        parameterization = "theta",
        estimator = "WLSMV")
an1 <- anova(fit_baseline, fit_loadinginv)
an2 <- anova(fit_loadinginv, fit_thresholdinv)
an3 <- anova(fit_thresholdinv, fit_uniquenessinv)

tab01 <- bind_rows(
  as_tibble(an1)[2,],
  as_tibble(an2)[2,],
  as_tibble(an3)[2,]
) %>%
select("Chisq", "Df", chisq_diff = `Chisq diff`, df_diff = `Df diff`, pvalue = `Pr(>Chisq)`,
mutate(
  stars = stars.pval(pvalue),
  chisqt = paste0(round(Chisq, 2), " (", Df, ")"),
  decision = ifelse(pvalue > 0.05, "Accept", "Reject"),
  model = c("Weak", "Strong", "Strict")
) %>%
bind_rows(
  tibble(Chisq = an1$Chisq[1], Df = an1$Df[1], chisq_diff = NA, df_diff = NA,
    pvalue = NA, stars = "", chisqt = paste0(round(an1$Chisq[1], 2), " (", an1$Df[1], ")"),
    decision = "Reference", model = "Configural")
) %>%
select(model, chisqt, chisq_diff, df_diff, pvalue, stars, decision) %>%
mutate(model = factor(model, levels = c("Configural", "Weak", "Strong", "Strict"))) %>%
arrange(model)

fit.meas <- dplyr::bind_rows(lavaan::fitmeasures(fit_baseline, output = "matrix")[c("chisq", "df", "p", "stars", "chisqt", "diff", "decision", "model")],
  lavaan::fitmeasures(fit_loadinginv, output = "matrix")[c("chisq", "df", "p", "stars", "chisqt", "diff", "decision", "model")],
  lavaan::fitmeasures(fit_thresholdinv, output = "matrix")[c("chisq", "df", "p", "stars", "chisqt", "diff", "decision", "model")],
  lavaan::fitmeasures(fit_uniquenessinv, output = "matrix")[c("chisq", "df", "p", "stars", "chisqt", "diff", "decision", "model")])

fit.meas <- fit.meas %>%
  dplyr::mutate(diff.chi2 = chisq - lag(chisq, default = dplyr::first(chisq)),
    diff.df = df - lag(df, default = dplyr::first(df)),
    diff.cfi = cfi - lag(cfi, default = dplyr::first(cfi)),
    diff.rmsea = rmsea - lag(rmsea, default = dplyr::first(rmsea))) %>%
  round(3) %>%

```

```

dplyr::mutate(rmse.ci=paste0(rmse," \n ", "(" ,rmse.ci.lower,"-",rmse.ci.upper,""))

tab.inv <- dplyr::bind_cols(tab01,fit.meas) %>%
  dplyr::select(model,chisqt,cfi,rmse.ci,diff.chi2,diff.df,diff.cfi,diff.rmsea,stars,dec
dplyr::mutate(diff.chi2=paste0(diff.chi2," (",diff.df,") ",stars)) %>%
  dplyr::select(model,chisqt,cfi,rmse.ci,diff.chi2,diff.cfi,diff.rmsea,decision)

col.nam <- c("Model",&chi;^2 (df)","CFI","RMSEA (90 CI)",
             "&Delta; &chi;^2 (&Delta; df)","&Delta; CFI","&Delta; RMSEA","Decision")

tab.inv %>%
  kableExtra::kable(format = "markdown",
                    align = "c",
                    booktabs = T,
                    escape = F,
                    caption = NULL,
                    col.names = col.nam) %>%
  kableExtra::kable_styling(full_width = F,
                            latex_options = "hold_position",
                            bootstrap_options=c("striped", "bordered", "condensed"),
                            font_size = 9)
knitr::opts_chunk$set(echo = TRUE, cache = T)
library(knitr)

fa_table <- function(x, varlabels = NULL, title = "Factor analysis results", diffuse = .10)
#get sorted loadings
require(dplyr)
require(purrr)
require(tibble)
require(gt)
if(sort == TRUE) {
  x <- psych::fa.sort(x)
}
if(!is.null(varlabels)) {
  if(length(varlabels) != nrow(x$loadings)) { warning("Number of variable labels and num
call. = FALSE) }

  if(sort == TRUE) {
    varlabels <- varlabels[x$order]

```

```

    }
  }
  if(is.null(varlabels)) {varlabels <- rownames(x$loadings)}

  loadings <- data.frame(unclass(x$loadings))

  #make nice names
  factornamer <- function(nfactors) {
    paste0("Factor_", 1:nfactors)}

  nfactors <- ncol(loadings)
  fnames <- factornamer(nfactors)
  names(loadings) <- fnames

  # prepare locations
  factorindex <- apply(loadings, 1, function(x) which.max(abs(x)))

  # adapted from from sjplot: getremovableitems
  getRemovableItems <- function(dataframe, fctr.load.tltn = diffuse) {
    # clear vector
    removers <- vector(length = nrow(dataframe))
    # iterate each row of the data frame. each row represents
    # one item with its factor loadings
    for (i in seq_along(removers)) {
      # get factor loadings for each item
      rowval <- as.numeric(abs(dataframe[i, ]))
      # retrieve highest loading
      maxload <- max(rowval)
      # retrieve 2. highest loading
      max2load <- sort(rowval, TRUE)[2]
      # check difference between both
      if (abs(maxload - max2load) < fctr.load.tltn) {
        # if difference is below the tolerance,
        # remeber row-ID so we can remove that items
        # for further PCA with updated data frame
        removers[i] <- TRUE
      }
    }
  }

  # return a vector with index numbers indicating which items
  # have unclear loadings

```

```

    return(removers)
  }
  if(nfactors > 1) {
    removable <- getRemovableItems(loadings)
    cross_loadings <- purrr::map2(fnames, seq_along(fnames), function(f, i) {
      (abs(loadings[,f] > cross)) & (factorindex != i)
    })
  }

  small_loadings <- purrr::map(fnames, function(f) {
    abs(loadings[,f]) < small
  })

  ind_table <- dplyr::tibble(varlabels, loadings) %>%
    dplyr::rename(Indicator = varlabels) %>%
    dplyr::mutate(Communality = x$communality, Uniqueness = x$uniquenesses, Complexity = x$complexity) %>%
    dplyr::mutate(across(starts_with("Factor"), round, 3)) %>%
    dplyr::mutate(across(c(Communality, Uniqueness, Complexity), round, 2))

  ind_table <- ind_table %>% gt(rowname_col = "Indicator") %>% tab_header(title = title)
  # mark small loadings
  for(f in seq_along(fnames)) {
    ind_table <- ind_table %>% tab_style(style = cell_text(color = "#D3D3D3", style = "italic"),
                                         locations = cells_body(columns = fnames[f], rows = small_loadings[[f]]))
  }
  # mark cross loadings

  if (nfactors > 1) {
    for (f in seq_along(fnames)) {
      ind_table <-
        ind_table %>% tab_style(
          style = cell_text(style = "italic"),
          locations = cells_body(columns = fnames[f], rows = cross_loadings[[f]])
        )
    }
  }
  # mark non-assignable indicators
  ind_table <-
    ind_table %>% tab_style(style = cell_fill(color = "#D93B3B"),
                           locations = cells_body(rows = removable))

```



```

}

# adapted from https://www.anthonyschmidt.co/post/2020-09-27-efa-tables-in-r/
Vaccounted <- x[["Vaccounted"]]
colnames(Vaccounted) <- fnames
if (nfactors > 1) {
  Phi <- x[["Phi"]]
  rownames(Phi) <- fnames
  colnames(Phi) <- fnames
  f_table <- rbind(Vaccounted, Phi) %>%
    as.data.frame() %>%
    rownames_to_column("Property") %>%
    mutate(across(where(is.numeric), round, 3)) %>%
    gt() %>% tab_header(title = "Eigenvalues, Variance Explained, and Factor Correlation")
}
else if(nfactors == 1) {
  f_table <- rbind(Vaccounted) %>%
    as.data.frame() %>%
    rownames_to_column("Property") %>%
    mutate(across(where(is.numeric), round, 3)) %>%
    gt() %>% tab_header(title = "Eigenvalues, Variance Explained, and Factor Correlation")
}

return(list("ind_table" = ind_table, "f_table" = f_table))

}

db_w1 <- db_long %>% filter(ola==1) %>% select(starts_with("perc"),
  starts_with("pref"))
corMat <- round(cor(db_w1), 2)
KMO(corMat)
cortest.bartlett(corMat, n = 846)
fac_pa <- fa(r = db_w1, nfactors = 4, fm= "pa")
#summary(fac_pa)
fac_pa
  tab_fa(db_w1, method = "ml", rotation = "varimax", show.comm = TRUE)
KMO(corMat)
cortest.bartlett(corMat, n = 846)
scree.plot(db_w1)
fac_pa_t<-fa_table(fac_pa)

```

```
fac_pa_t$ind_table  
fac_pa_t$f_table
```